

Informe explicativo

Análisis de la popularidad de canciones en Spotify

Proyecto final · EDA y Dashboard

1. Introducción y objetivos

Objetivo. Analizar qué factores están relacionados con la popularidad de las canciones en Spotify, combinando información de canciones y de artistas, mediante técnicas de análisis exploratorio, análisis estadístico y visualización de datos.

Para ello se ha trabajado con un dataset de más de 550.000 canciones, que incluye tanto características propias de cada canción (energía, bailabilidad, duración, tempo...) como información de los artistas que las interpretan (popularidad, número de seguidores). El análisis se ha planteado en torno a las siguientes preguntas:

1. ¿Qué géneros presentan mayor popularidad media?
2. ¿Cómo ha evolucionado la popularidad de las canciones a lo largo de las décadas?
3. ¿Existe relación entre las colaboraciones entre artistas y la popularidad?
4. ¿Los artistas con más seguidores obtienen canciones más populares?
5. ¿Influye la duración de una canción en su popularidad?
6. ¿Qué características musicales diferencian a las canciones más populares del resto?

El proyecto se ha desarrollado en dos fases: una primera de limpieza, transformación y análisis exploratorio realizada en **Python**, y una segunda de preparación final de los datos y construcción de un dashboard interactivo, realizada en **Excel con Power Query**.

2. Los datos y su preparación

El dataset final contiene 550.582 canciones y 32 variables. Durante la limpieza se detectaron numerosos posibles duplicados lógicos, principalmente canciones con el mismo título, álbum y artista, pero las comprobaciones realizadas mostraron que no se trataba de duplicados exactos, ya que los registros presentaban distintos identificadores de canción y, en algunos casos, diferencias en sus características. Por este motivo, no se eliminaron automáticamente.

Se trata de un conjunto amplio y heterogéneo: incluye artistas con audiencias muy reducidas junto a algunos de los más escuchados del mundo, y música de más de un siglo de antigüedad, aunque la mayoría de las canciones corresponden a la década de 2010, coincidiendo con el periodo de mayor volumen de publicaciones en la plataforma.

La preparación de los datos incluyó la normalización de textos (mayúsculas, espacios, caracteres especiales), la conversión de columnas almacenadas como texto pero que en realidad representaban listas (por ejemplo, la lista de artistas de una canción) a un formato analizable, y el tratamiento de los valores ausentes detectados.

A partir de los datos limpios se crearon varias variables adicionales necesarias para el análisis y para el dashboard: el artista principal y el número de artistas de cada canción, si se trata de una colaboración, la década de lanzamiento, la duración en minutos, los seguidores del artista en millones, y una clasificación de las canciones en cinco niveles de popularidad (de "Baja" a "Muy Alta").

3. Resultados del análisis exploratorio


3.1 Perfil general de canciones y artistas

La mayoría de las canciones del dataset presenta una popularidad baja, mientras que solo un grupo reducido alcanza valores altos, un patrón habitual en plataformas de streaming, donde conviven muchas canciones de bajo consumo con un número limitado de grandes éxitos. En cuanto a duración, la mayoría se sitúa entre 3 y 4,5 minutos, el rango característico de la música comercial. A nivel musical, predominan canciones con energía alta y bailabilidad media, con un tempo concentrado en torno a los 120 BPM.

3.2 Relación entre artista y popularidad de la canción

Dentro de las variables analizadas, la popularidad media del artista es la que presenta una relación más clara con la popularidad de sus canciones, por encima de las características musicales estudiadas.

La popularidad media del artista es la variable con mayor correlación respecto a la popularidad de sus canciones, si bien se trata de una relación moderada. Sus seguidores presentan una relación algo menor. Las características musicales, en cambio, muestran correlaciones más débiles: la bailabilidad es la que presenta mayor relación, aunque limitada, mientras que la energía apenas guarda relación con la popularidad.



Mapa de correlaciones entre las principales variables numéricas del dataset.

Esto no implica que las características musicales carezcan de relevancia, sino que, de forma aislada, explican poco de la popularidad. En los datos analizados, las variables relacionadas con el artista presentan una relación más clara con la popularidad que las características musicales estudiadas de forma individual.

3.3 Género y década

La popularidad media varía según el género, aunque no de forma muy pronunciada. **Hip-Hop** es el género con mayor popularidad media (24,58), seguido de R&B (21,32); en el extremo opuesto se sitúan blues, folk y rock, todos por debajo de 16 puntos. La mayoría de los géneros se concentra en una franja similar, entre 15 y 20 puntos, lo que sugiere que el género influye en la popularidad, pero no es el factor determinante.

Por décadas, la evolución es más marcada: la popularidad media aumenta progresivamente hasta alcanzar su valor máximo en los años 70 (25,89) y se mantiene alta en los 80, desciende hasta un mínimo en los años 2000 (14,77) y vuelve a recuperarse en la década más reciente. Los resultados de las primeras décadas (1900-1910) deben interpretarse con cautela, debido al reducido número de canciones representadas en esos periodos.

3.4 Seguidores, colaboraciones y duración

Un mayor número de seguidores no garantiza canciones más populares: son variables relacionadas, pero no equivalentes. Un artista con millones de seguidores puede tener canciones con niveles de popularidad muy distintos entre sí. Por este motivo, el dashboard separa ambas perspectivas en dos gráficos distintos: uno muestra el ranking de artistas por seguidores, y otro compara la popularidad media según el tamaño de audiencia del artista.

En cuanto a las colaboraciones, aproximadamente un 16% de las canciones del dataset están interpretadas por varios artistas. El análisis permite comparar su popularidad frente a las canciones de un único artista, si bien una diferencia entre ambos grupos no implica que la colaboración sea, por sí misma, la causa de una mayor popularidad; puede deberse también al género o a los artistas concretos implicados.

Respecto a la duración, las diferencias observadas son pequeñas, aunque se aprecia una ligera tendencia: la popularidad media es algo mayor en canciones de duración intermedia (entre 2,5 y 4,5 minutos) y desciende levemente hacia los extremos.


3.5 Características de las canciones más populares

Para analizar esta cuestión se comparó el 10% de canciones más populares con el conjunto completo del dataset. Las diferencias son moderadas: las canciones más populares presentan mayor **bailabilidad** (0,59 frente a 0,53) y un **valence** ligeramente superior (0,49 frente a 0,46). En energía y tempo apenas se observan diferencias, y su duración media es solo algo menor (3,82 frente a 3,96 minutos).

En conjunto, el rasgo que más distingue a las canciones más populares no es un patrón musical marcado, sino una tendencia leve hacia canciones algo más bailables y con un ánimo algo más positivo.

4. Dashboard interactivo

Los resultados del análisis se han integrado en un dashboard construido en Excel, que permite explorar la información sin necesidad de acceder al código. Se organiza en tres bloques: tres indicadores principales (KPIs) en la parte superior, seis gráficos en la zona central, y cuatro filtros en el lateral que permiten cruzar la información.



Vista general del dashboard final.

Los tres KPIs resumen la popularidad media del conjunto seleccionado, el porcentaje de canciones que corresponden a colaboraciones, y el género con mayor popularidad media en cada momento. Este último se actualiza según los filtros aplicados de forma intencionada, para poder responder preguntas como "¿qué género destaca en una década concreta?" en lugar de ofrecer un único resultado fijo.

Los seis gráficos recorren cada una de las preguntas planteadas al inicio del proyecto: popularidad por género, evolución por década, ranking de artistas por seguidores, comparación de características musicales (Top 10% frente al conjunto completo), popularidad según el alcance del artista, y popularidad según la duración de la canción.

Los cuatro filtros (género, década, tipo de colaboración y nivel de popularidad) no se conectaron de forma indiscriminada a todos los elementos. Cuando un filtro y un gráfico comparten la misma variable de base —por ejemplo, filtrar por nivel de popularidad y a continuación consultar la popularidad media— el resultado resulta poco informativo. Por ello, las conexiones se definieron de forma individual, gráfico a gráfico, para que cada filtro aportara contexto real en lugar de repetir información ya conocida.

5. Conclusiones principales

La popularidad de una canción es un fenómeno multidimensional: El género, la época, la colaboración, la audiencia del artista, la duración y las características musicales muestran relaciones diferentes con la popularidad, pero ninguna de estas variables explica por sí sola las diferencias observadas.

Dentro de las variables analizadas, la popularidad del artista presenta la relación más clara con la popularidad de las canciones, mientras que las características musicales muestran relaciones más débiles. El género y la década aportan contexto más que respuestas definitivas: Hip-Hop lidera en el conjunto general, pero ese resultado puede variar según la década o el tipo de colaboración analizados, lo que justifica el uso de un dashboard filtrable frente a una conclusión estática.

Asimismo, se confirma que un mayor número de seguidores no equivale a una mayor popularidad de las canciones: son variables relacionadas pero distintas. Por último, las características musicales sí influyen, aunque de forma más sutil de lo esperado: las canciones más populares tienden a ser algo más bailables y con un ánimo ligeramente más positivo, sin que exista un patrón musical marcado que las diferencie claramente del resto.

6. Limitaciones y posibles líneas futuras

El análisis realizado es de carácter exploratorio: permite identificar relaciones y asociaciones dentro de los datos, pero no establece relaciones de causalidad. La métrica de popularidad de Spotify, además, puede estar influida por factores no recogidos en este dataset, como la promoción recibida por una canción o su inclusión en listas de reproducción destacadas.

7. Conclusión final

El proyecto ha cubierto el proceso completo de análisis de datos: limpieza y preparación en Python, un análisis exploratorio que ha dado respuesta a las preguntas planteadas al inicio y un dashboard interactivo que traslada estos resultados a una herramienta accesible.

El principal resultado es que el contexto y la posición del artista presentan una relación más clara con la popularidad de las canciones que una característica musical concreta. Las canciones más populares presentan algunas diferencias musicales, especialmente en bailabilidad y valence, pero estas son relativamente pequeñas.

En definitiva, los resultados muestran que la popularidad de una canción depende de la combinación de distintos factores relacionados con el artista, el contexto temporal y las características de la propia canción.